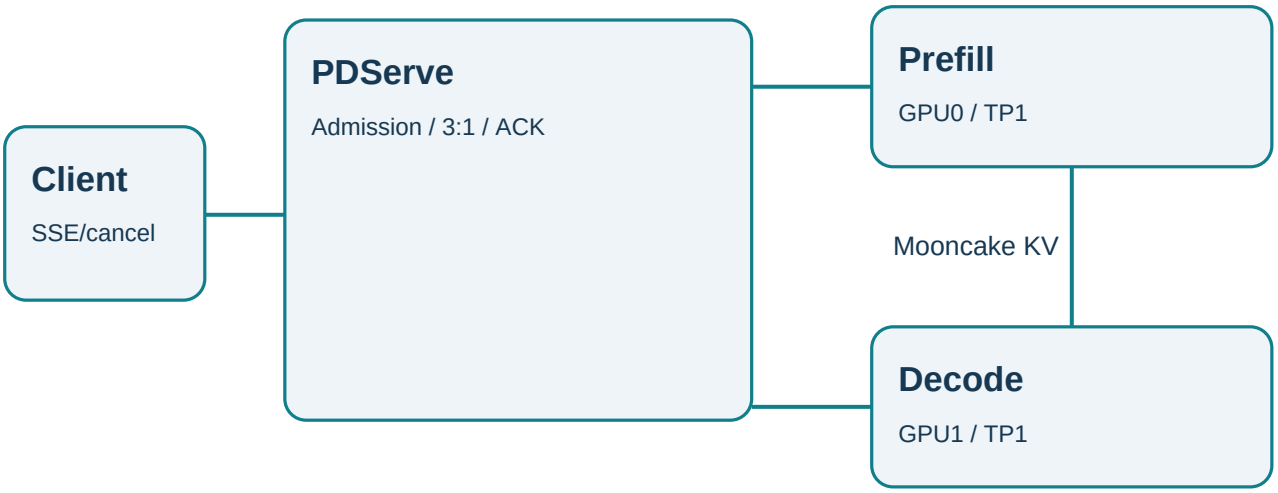
PDServe

面向混合长短请求的
Prefill / Decode 分离推理服务

开源候选与求职展示报告

基于远程实际项目的源码、历史实验和证据审核



公开候选：2026-10-25 | 固定推理模型：Qwen2.5-7B-Instruct

历史硬件：2 × A100 80GB；TP=1、PP=1；36次正式运行、1440个请求。

本轮只执行CPU、补丁重建、统计复核及文档检查；没有训练、下载模型或重新运行GPU。

01 摘要与项目边界

长输入Prefill、逐token Decode和KV传输具有不同的资源特征。PDServe围绕容量准入、排队公平性与故障后的真实资源释放建立了一个可观测服务层，服务于单机双GPU研究场景。

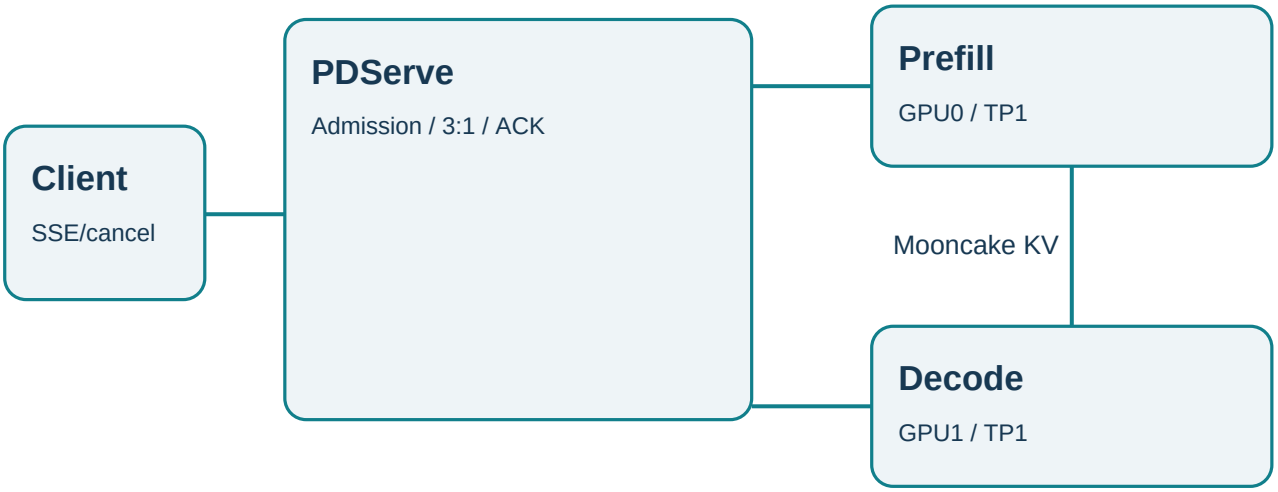
维度	本项目完成	不作的承诺
模型执行	复用SGLang；固定Qwen2.5-7B-Instruct BF16	没有训练、微调或模型质量提升
服务层	token/KV/slot预算、队列、SSE与取消	不是完整OpenAI API或生产平台
可靠性	真实清理ACK、隔离和显式epoch恢复	没有自动进程重启或分布式容灾
评测	真实推理历史、36次raw复算	不代表真实业务效果或容量极限

可执行的交付

候选包含核心源码、固定上游补丁、无GPU测试、合成输入、脱敏统计、README、迭代历史与手动上传工具。完整原始响应和机器标识保留在私有证据中。公开摘要和原证据分别记录哈希，绝不混同。

实际远程提交为aef33d6；候选不是新的算法版本。SGLang执行模型，Mooncake执行通信，本项目新增服务编排和观测/生命周期逻辑。

02 问题、架构与请求流程



客户端请求先经tokenizer精确编码；队列选择能同时容纳P/D预算的请求。Prefill计算完成后，Mooncake将KV交给Decode；后者逐步输出，网关把结果转成completion SSE。

响应结束不代表KV已释放。网关等待每个角色的allocator、metadata、compute和transport清理证明，并以epoch、内部请求ID和bootstrap room关联。资源无法确认时保留租约并隔离。

组件	公开源码
预算与队列	src/pdserve/core.py
请求生命周期	src/pdserve/service.py
协议与API	protocol.py / api.py / backend.py
严格上下文边界	context_guard.py
引擎观测与清理	patches/ 与 engine_modules/
客户端统计	benchmarks/analyze.py / aggregate.py

03 准入、调度与关键不变量

P预留输入token；D预留输入与最大输出之和，按KV page取整。每个节点预算不超过实际KV与slot容量的90%。单事件循环中的原子预留不含await，因此P/D不会只预留一半。

参数	历史采用值	说明
上下文	16384	input+max_output必须严格小于上限
短请求阈值	2048 token	同类保持FIFO
公平轮转	S:S:S:L	可容纳的长请求等待≥5s后优先
有界队列	128；超时30s	专项验收使用queue4/active2
活动slot	参数32；有效29	历史引擎slot33，保留10%余量
混合基线	每副本32，总计64	相同GPU的架构对照，不是等总并发消融

实现与性能证据分开

Stage2f专门构造排队，证明3:1、aging、队列拒绝和超时行为。36次性能运行均未发生网关派发重排，队列等待不足1ms；它们不能证明公平算法产生了性能改善。

04 故障生命周期与恢复

取消receipt只证明意图已接收。P采用计算与传输排空；D在KV-ready之前保持资源，之后才允许cooperative abort。客户端断开也需要把取消传播到相关实例。

事件	行为	释放条件
正常完成	保留响应终态和清理状态	两个角色分别收到完整cleanup ACK
取消/断连	显式终态，等待排空	compute=0及allocator/metadata/transport证明
节点退出/清理超时	整对隔离，拒绝新请求	不可自行清零未确认租约
成对恢复	旧进程退出，两个新epoch	旧租约标epoch_retired，不伪造ACK

历史故障验收覆盖排队、Prefill、传输、Decode取消、传输超时及P/D退出。公开候选保留相关逻辑和CPU证据检查；没有本轮GPU故障注入。

管理接口未鉴权，仅限本机实验。恢复接口信任人工old_pair_stopped确认，不具备独立进程退出证明。公开版没有通配杀进程或自动重启工具。

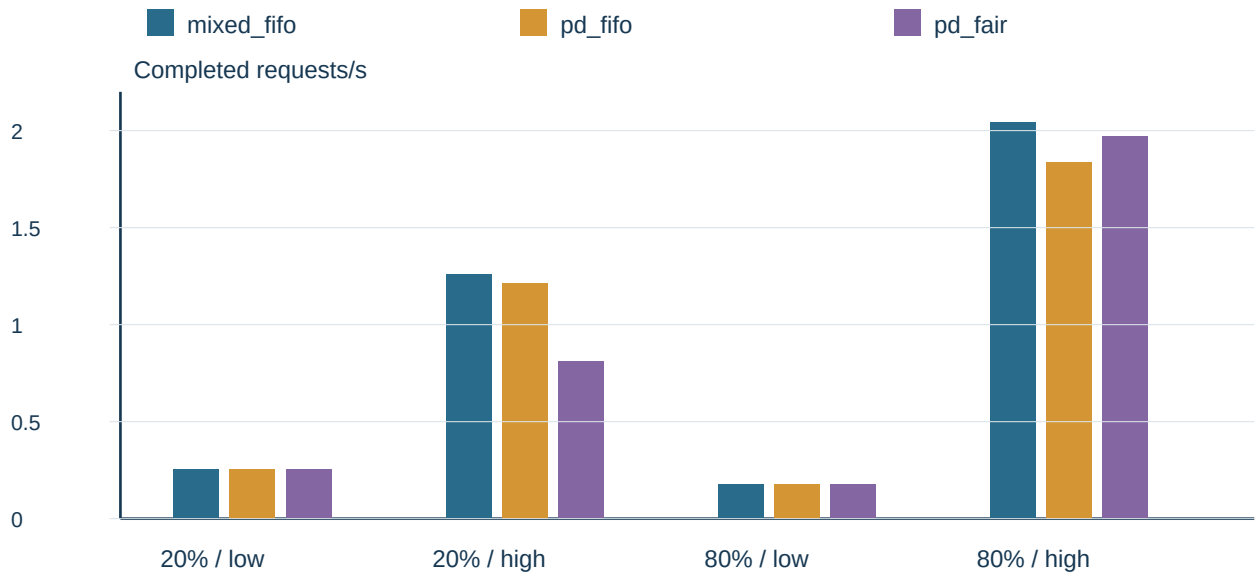
05 输入与实验设计

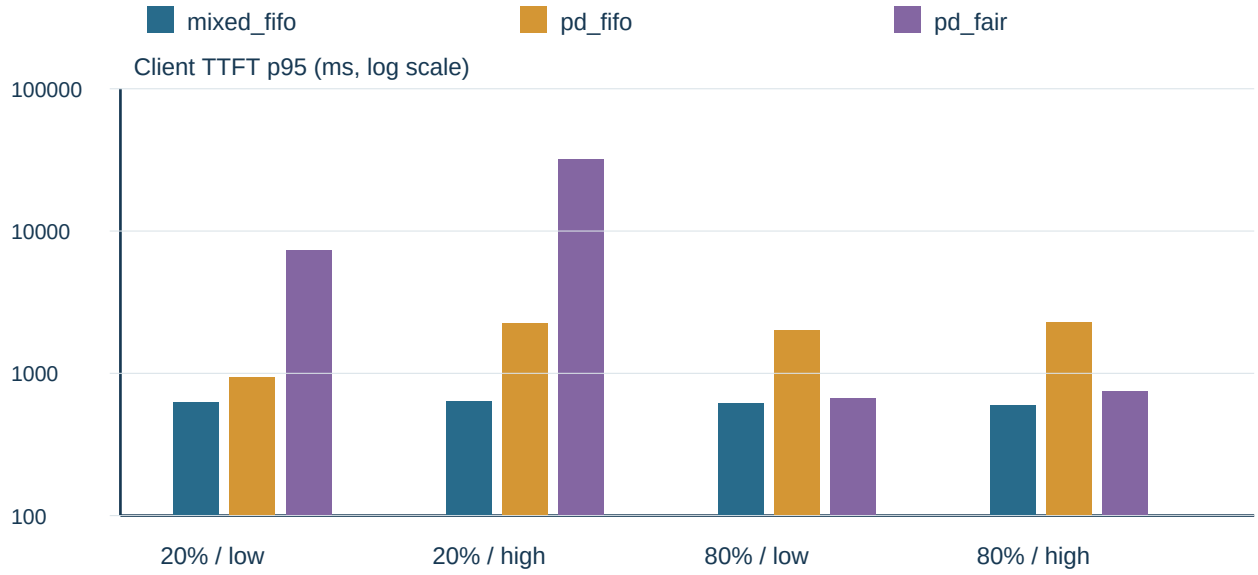
项目	设置
模型/精度	Qwen2.5-7B-Instruct；BF16；context16384
硬件	同一对A100-SXM4-80GB；TP=PP=1
输入/输出	512/8192输入；128/512输出，类内平衡
比例/到达	20%/80%短请求；0.25/2.0req/s开放环
规模	3配置×4场景×3重复×40请求=1440
控制	固定trace、seed2026、关闭前缀缓存
失败	正式运行全成功；1次失败尝试另存并报告

固定输入是合成token序列，不是业务数据集。没有模型准确率、训练loss或用户任务评分。模型文件本地SHA256已记录，上游revision未核实，重新下载的模型不能自动视为同字节。

历史目录的saturated是2req/s负载标签，并未做容量搜索或稳态判定。低负载吞吐由到达过程决定；有限窗口尾部排空影响完成吞吐。

06 总体结果与负结果





每个柱对应3次重复共120请求；TTFT为客户端统计，延迟图使用对数轴。正式摘要均无失败/拒绝。图表描述该配置会话，不代表算法因果收益或最大吞吐。

双混合副本在本组试验中总体更好；P/D没有普遍提速。完整分类p50/p95/p99、ITL覆盖率和逐repeat统计见docs/RESULTS.md及results/。

07 结果审查：哪些结论成立

80%短请求/2req/s时，P/D fair总体TTFT p95为752.86ms，FIFO为2297.31ms；完成吞吐分别1.9695和1.8362req/s。观测上约降低67.2%、提高7.3%，但没有网关重排，不能写成“公平调度算法带来67%优化”。

双副本同场景为2.0441req/s，fair仍低约3.6%。长请求占80%的高到达率场景，fair吞吐低于双副本约35.5%，TTFT明显退化。

限制	证据与解释
重复波动	fair长请求高到达率TTFT p95约35.62s、10.71s、1.48s；含失败后重启条件
传输口径	Prefill完成到transfer_completed包含等待/worker/poll窗口，不是纯网络耗时
观测混杂	P/D每0.25s获取阶段状态；mixed每1s轮询metrics
ITL口径	只统计+1帧；配置覆盖率不同，不是全token无偏分布
尾部样本	每类别可能只有24请求，p99仅为样本描述

下一步需要真正触发队列的匹配并发消融、随机交错配置、统一观测和闭环在途Prefill限制。本轮不重跑模型来补造证据。

08 实际迭代与采用版本

组件阶段	相比前版变化	验证/最终采用
模型/适配器	无；同一7B模型，无训练	本地hash；revision缺口保留
Stage1	固定环境与stock P/D链路	单卡及真实双卡；底座
Stage2a/b/b2/c1	阶段事件、真实ACK、取消、超时guard	CPU+历史双卡；最终合并10文件
Stage2d/e/f	网关预算、严格context、节点退出、调度专项	CPU+专项真卡；核心字节保留
Stage3a/b/c/d	客户端测量、双副本/PD基线、硬件绑定campaign	最终36次；未拼接旧卡数据
Stage3d fix1-6	超时、失败sidecar、ITL口径、mixed轮询策略	测量工具修订，不是算法升级
Stage4/公开候选	私有交付转公开范围、便携入口、PDF与CI	本轮CPU重建；新入口未GPU验收

详细历史按模型、输入、工具执行、算法、评测与发布分别记录在docs/ITERATION_HISTORY.md。旧ZIP修订不当作性能提升版本；原始历史验收清单没有被刷新。

09 最小示例与故障演示

无GPU：Windows或Linux，候选目录

```
python tools/check.py
python examples/mock_scheduler.py
python tools/summarize_results.py
```

mock示例只展示合成队列；不声称KV传输或真实模型服务。本轮未启动任何GPU进程。

真实Linux服务：用户手动执行

```
python scripts/serve_backend.py prefill --model-path "$MODEL"
python scripts/serve_backend.py decode --model-path "$MODEL"
python -m pdserve.launch fair --model-path "$MODEL"
python examples/sse_client.py --request-id demo-001
```

每条服务命令在独立终端运行，先完成依赖、模型与补丁设置。使用cancel接口观察receipt、终态和ACK分离；节点退出只关闭自己启动的后端终端，保留网关隔离状态。

恢复必须确认旧P/D都已停止并启动新epoch。不要把人工old_pair_stopped=true当成自动进程证明，不要自动重试已开始输出的请求。详见docs/DEMO.md。

10 依赖、重建与新实验

历史环境固定SGLang0.4.6.post5、torch2.6.0+cu124、FlashInfer0.2.5+cu124torch2.6、sgl-kernel0.1.4、Mooncake0.3.2、transformers4.51.1和compressed-tensors0.9.3。完整freeze在requirements/。

```
python tools/rebuild_engine.py \
  --upstream work/upstream-sglang/python \
  --output work/patched-site
```

重建只写新目录，before不匹配就停止；10个after hash全部检查。本轮用证据中的stock字节重建成功，没有重新下载上游或安装GPU包。

```
export PYTHONPATH="$PWD/src:$PWD/work/patched-site:$PWD/benchmarks"
python scripts/preflight.py pd_fair --model-path "$MODEL"
python benchmarks/run_pilot.py pd_fair --campaign my-new-run
python benchmarks/run_matrix.py pd_fair --campaign my-new-run
```

新campaign绑定当前硬件、模型/依赖和候选清单；变化时拒绝续跑。模型revision缺口、旧wheel可用性及新目录GPU部署均明确未验证。完整分平台命令以README和REPRODUCE为准。

11 公开范围、来源与许可

保留：服务实现、必要测试、固定上游补丁、合成trace、脱敏组统计和说明。排除：权重、环境、旧.git、完整第三方树、原始响应、主机名、GPU UUID、boot ID、内部地址和历史归档。

464个私有采集文件通过哈希；12个历史evidence归档与远程哈希一致；37份raw逐文件匹配；36份summary从frames复算一致。公开产物独立记录自己的hash与提取规则，不伪装成原始证据。

许可：候选采用Apache-2.0，保留已安装SGLang许可证及上游归属。只有上游修改diff与项目新增模块入库；Mooncake、FlashInfer、PyTorch和Qwen权重通过外链使用。个人作者身份和GitHub地址没有编造。

模型效果、系统效果、模拟测试和真实推理历史分别标注。项目使用AI辅助开发与文档整理，远程实验由持有人执行；求职展示应说明个人实际理解和操作。

参考资源

SGLang fixed tag: github.com/sgl-project/sglang/tree/v0.4.6.post5

Mooncake fixed tag: github.com/kvcache-ai/Mooncake/tree/v0.3.2

Qwen model: huggingface.co/Qwen/Qwen2.5-7B-Instruct

12 验收记录与交付使用

检查	本轮结果/范围
审查来源	远程盘点+审查包；旧附件只在hash一致后复用
原始统计	36份summary复算一致；37份raw hash匹配
核心单元测试	见docs/CHECKS；标准库CPU运行，无GPU/网络
补丁重建	10个最终目标与远程接受的字节hash一致
源码保持	继承核心原字节保存；便携入口单列适配
文档/PDF	相对链接、公开范围、图表口径和逐页渲染检查
未执行	GPU启动、依赖安装、模型下载、训练、业务/生产验证
GitHub	用户手动上传；未自动commit/push，无凭据访问

最终交付包含独立GitHub候选ZIP、本中文PDF、详细README和迭代历史、来源映射、公开范围/缺口、检查记录，以及Windows手动上传脚本。候选没有Git历史，避免携带私有信息；已有仓库采用干净工作区上的增量更新，不重新初始化或强推。

本报告的主要价值是可审阅的服务实现和诚实的证据边界。它不把PD等同于提速，也不把模拟与静态检查当作真实模型验收。